

Лабораторная работа №3

Вариационный ряд

Цель работы: вычислить математические характеристики вариационного ряда

Оборудование: ПК, табличный процессор Excel.

Задание №1

Задание № 1.

В качестве изучаемого признака рассматривается число продаж каждого из 26 случайно выбранных продавцов универсама:

16, 12, 15, 15, 23, 9, 15, 13, 14, 14, 21, 15, 14, 17, 27, 15, 16, 12, 16, 19, 14, 16, 17, 13, 14, 14.

Необходимо сделать следующее:

- 1) Построит вариационный ряд;
- 2) Провести анализ построенного вариационного ряда:

9 12 12 13 13 14 14 14 14 14 14 15 15 15 15 15 16 16 16 16 17 17 19 21 23 27

Вариационный ряд

x_i	9	12	13	14	15	16	17	19	21	23	27
m_i	1	2	2	6	5	4	2	1	1	1	1

Анализ построенного вариационного ряда

1. Среднее значение признака М

Среднее арифметическое является приближённой оценкой

теоретического среднего (математического ожидания — М) генеральной

совокупности величин $x_1, x_2, \dots, x_n$ и определяется по формуле

$$\bar{x} = M = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$M = (9 \cdot 1 + 12 \cdot 2 + \dots + 27 \cdot 1) / 26 = 15,615$$

2. Дисперсия и среднее квадратичное отклонение

Дисперсия. Среднее арифметическое является показателем среднего уровня, вокруг которого колеблются значения членов вариационного ряда. Элементы исследуемой выборки (массива) могут быть по-разному расположены относительно своего среднего значения. Степень рассеивания элементов массива вокруг среднего значения характеризуется дисперсией

$$D = \frac{(x_1 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

$$D = (43,758 + 13,068 + 6,838 + 2,608 + 0,378 + 0,148 + 1,918 + 11,458 + 28,998 + 54,538 + 129,618) / 26 = 11,281$$

Средним квадратическим отклонением (или стандартным отклонением) величин $x_1, x_2, \dots, x_n$ от их среднего значения называется корень квадратный из дисперсии

$$S = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}}$$

$$S = \sqrt{11,281} \approx 3,359$$

3. Коэффициент вариации

Среднее квадратическое отклонение имеет ту же размерность, что и элементы исходного массива. Это не даёт возможности сравнить между собой степень рассеяния (изменчивости) разнородных величин. Для этой цели введён коэффициент вариации (коэффициент изменчивости) C

$$C = v = \frac{S}{M} \cdot 100\%$$

$$C = 3,359 / 15,615 \cdot 100\% = 21,5\%$$

4. Коэффициент асимметрии

Третий центральный момент относительно среднего значения характеризует асимметрию распределения относительно математического ожидания и является, следовательно, мерой асимметрии (скошенности).

Для симметричного распределения $M_3 = 0$. Если $M_3 < 0$, то график плотности асимметричен и скошен отрицательно — пик смещён вправо, а при $M_3 > 0$ — пик смещён влево.

Для удобства вычислений показателю асимметрии придают безразмерную величину, для этого M_3 делят на S^3 (куб среднего квадратического отклонения)

$$A = \frac{\sum_{i=1}^n (x_i - M)^3}{n \cdot S^3}$$

$$\wedge = ((9-15,615)^3 + (12-15,615)^3 + \dots + (27-15,615)^3) / (26 \cdot 3,359^3) \approx 1,743$$

5. Эксцесс

Четвёртый центральный момент характеризует свойство островершинности или пологости кривой плотности вероятностей. За характеристику этого свойства принимается безразмерная величина E' , называемая эксцессом и равная отношению M_4 к M_2^2 , которое для нормального распределения равно 3.

Если $S' = 1$ и $M_4 > 3$, то график плотности распределения имеет эксцесс, превышающий нормальный (кривая заострена, т.е. $E' > 0$).

Если $M_4 = 3$ — то нормальный эксцесс — средняя заострённость, т.е. $E' = 0$;

Если $M_4 < 3$, то кривая плоская и имеет эксцесс менее нормального, т.е. $E' < 0$.

Значение эксцесса по результатам наблюдений вычисляется по формуле

$$E' = \frac{\sum_{i=1}^n (x_i - M)^4}{n \cdot S^4} - 3 \qquad E = \frac{1}{ns^4} \sum_{i=1}^n (x_i - \bar{x})^4 - 3$$

$$E = ((9-15,615)^4 + (12-15,615)^4 + \dots + (27-15,615)^4) / (26 \cdot 3,359^4) - 3 \approx 3,916$$

6. Мода и медиана плотности распределения

Мода — это значение признака, наиболее часто встречающееся в вариационном ряду. Обозначается M_o . Моде или *модальному интервалу* признака, соответствует наибольший подъем (вершина) графика распределения частот. Если график распределения частот имеет одну вершину, то такое распределение называется *унимодальным*.

$$M_o = 14$$

Второй квартиль (50-й перцентиль). Он называется медианой и обозначается M_e .

Медиана — это такое значение признака, которого делит упорядоченное (ранжированное) множество данных пополам так, что одна половина всех значений оказывается меньше медианы, а другая — больше. Первым шагом при определении медианы является упорядочивание (ранжирование) всех значений по возрастанию или убыванию.


Просмотрим ранжированные варианты. Видим, что значение 13-го по порядку варианта равно 15. Значение 14-го по порядку варианта также равно 15. Отсюда 50-й перцентиль равен 15.

$$M_e = 15$$

7. Показателем вариации является вариационный размах R

$$R = x_{\max} - x_{\min}$$

$$R = 27 - 9 = 18$$



Анализ

Исходя из данных, можно сказать, что у нас есть довольно заметная положительная асимметрия и высокий коэффициент вариации, что говорит о значительной изменчивости в данных. Есть некоторое смещение влево в данных (что показывают коэффициент асимметрии и эксцесс), а также большое стандартное отклонение (что подчеркивает высокий коэффициент вариации). Кроме того, эксцесс указывает на острый пик, что может свидетельствовать о наличии выбросов или необычных значений. В целом, это может указывать на то, что у нас есть довольно разнообразный набор данных, имеющий относительно широкий размах значений.

Задание №2, №3

Задание № 2.

Менеджер большого универмага зафиксировал суммы денег, которые израсходовали 184 покупателя, посетившие отдел верхней одежды в день сезонной распродажи по сниженным ценам. Зная минимальную и максимальную стоимости покупки, менеджер сгруппировал данные о суммах, израсходованных на покупки, в виде таблицы (таблица 1).

Таблица 1.
Суммы денег, израсходованные на покупки товаров в отделе верхней одежды (х, руб.)

Интервалы расходов	100-300	300-500	500-700	700-900	900-1100	1100-1300
Число покупателей (m_i)	30	38	50	31	22	13
Доля покупателей (w_i)	0.163	0.207	0.272	0.168	0.120	0.070

Вопросы:

1. Какова нижняя и верхняя границы интервалов (по таблице 1)?
2. Изучите распределение, представленное в таблице 2.

Задание № 3

Таблица 2

Интервалы	Число регионов
До 60	10
60-70	29
70-80	2
80-90	13
90-100	-
Свыше 100	6

Определите начало первого интервала и правую границу последнего интервала.

3. Для данных Задания № 1 определите оптимальную величину интервала и представьте ряд из этого задания в виде интервального ряда.
4. Интервальные ряды бывают с равными и неравными интервалами. Иногда при группировке с равными интервалами сначала определяют число интервалов (групп) z при заданном объеме совокупности, используя формулу:

$$L = 2 \ln n,$$

и тогда k в формуле Стелжера вычисляется по формуле

$$k = \frac{x_{\max} - x_{\min}}{L}$$

Для Задания 1 вычислите оптимальную величину интервала по данной формуле и сравните его с интервалом, вычисленным по формуле Стелжера.

5. Для данных таблицы 1 накопленные частоты и расположите их в таблице в восходящем порядке и в нисходящем порядке. На что они указывают? Поясните.
6. Постройте полигон распределения для Задания 1
7. Постройте гистограмму и кумулянту для данных таблицы 2
8. Постройте огиву для данных таблицы 2
Огива строится аналогично кумулянте (но по оси абсцисс откладываются накопленные частоты (частости), а по оси ординат – значения признака).
9. Для данных Задания № 1 вычислить:
 - 1) 25-й, 50-й и 90-й перцентили в вариационном ряду.
10. По данным таблицы 2 вычислить медиану (используйте формулу для нахождения медианы внутри медианного интервала).

11. По данным таблицы 2 вычислить моду (используйте формулу для нахождения моды внутри модального интервала).
12. Вычислите среднюю арифметическую для данных Задания № 1 по формулам:
 - Средней арифметической;
 - Средней арифметической взвешанной.
13. Проверить насколько медиана и средняя арифметическая чувствительна к положению крайних значений ряда значений (для данных Задания № 1).
14. Может ли быть в одном ряду несколько мод? Обоснуйте.
- 15.

Вопросы

№1

Нижние границы интервалов – 100, 300, 500, 700, 900, 1100

Верхние границы интервалов – 300, 500, 700, 900, 1100, 1300

№2

Интервалы	Число регионов
До 60	10
60-70	29
70-80	2
80-90	13
90-100	-
Свыше 100	6

Исходя из данных значений интервал составляет 10. Следовательно первый интервал будет 50-60, а последний интервал будет 100-110. Тогда, начало первого интервала – 50, а правая граница последнего интервала – 110.

№3

Задание № 1.

В качестве изучаемого признака рассматривается число продаж каждого из 26 случайно выбранных продавцов универсама:

16, 12, 15, 15, 23, 9, 15, 13, 14, 14, 21, 15, 14, 17, 27, 15, 16, 12, 16, 19, 14, 16, 17, 13, 14, 14.

Построить интервальный вариационный ряд.

1. По данным таблицы определяем $x_{\min} = 9$, $x_{\max} = 27$.

2. Разобьем множество значений выборки на интервалы. Число интервалов по формуле равно

$$k = 1 + 1,4 \ln 26 \approx 5,56$$

3. Выберем:

- число интервалов $k = 6$;

- начало первого интервала $a_1 = 9$;

- конец последнего, шестого, интервала $a_7 = 27$.

4. Длина каждого интервала будет равна

$$\Delta = \frac{a_7 - a_1}{k} = \frac{27 - 9}{6} = 3$$

5. Подсчитаем число вариантов, попадающих в каждый интервал. Получим вариационный ряд

x_i	[9;12)	[12;15)	[15;18)	[18;21)	[21;24)	[24;27)
m_i	1	10	11	1	2	1

№4

$$L = 2 \ln n,$$

$$K = \frac{x_{\max} - x_{\min}}{L}$$

$$L = 2 \ln(26) = 6,516 \approx 6$$

$$K = \frac{x_{\max} - x_{\min}}{L} = \frac{27 - 9}{6} = 3$$

№5

Суммы денег, израсходованные на покупки товаров в отделе верхней одежды (у.е.)						
Интервалы расходов	100-300	300-500	500-700	700-900	900-1100	1100-1300
Число покупателей (m_i)	30	38	50	31	22	13
Доля покупателей (w_i)	0.163	0.207	0.272	0.168	0.120	0.070

x_i	100-300	300-500	500-700	700-900	900-1100	1100-1300		
m_{xi}	30	68	118	149	171	184	Восходящий порядок	
	184	154	116	66	35	13	Нисходящий порядок	

Накопленной частотой в восходящем порядке означает сумму частот всех членов статистического ряда, предшествующих определенной категории, включая ее.

Накопленной частотой в нисходящем порядке называется суммарная частота членов статистического ряда, значения которых меньше x .

№6


Полигон распределения для дискретного вариационного ряда



№7

Таблица 2	
Интервалы	Число регионов
До 60	10
60-70	29
70-80	2
80-90	13
90-100	-
Свыше 100	6


Гистограмма



Кумулянта



№8



9. Для данных Задания № 1 вычислить:

1) 25-й, 50-й и 90-й перцентили в вариационном ряду.

Задание № 1.

В качестве изучаемого признака рассматривается число продаж каждого из 26 случайно выбранных продавцов универсама:

16, 12, 15, 15, 23, 9, 15, 13, 14, 14, 21, 15, 14, 17, 27, 15, 16, 12, 16, 19, 14, 16, 17, 13, 14, 14.

Необходимо сделать следующее:

- 1) Построит вариационный ряд;
- 2) Провести анализ построенного вариационного ряда:

9 12 12 13 13 14 14 14 14 14 14 15 15 15 15 15 16 16 16 16 17 17 19 21 23 27

25-й перцентиль

1) Найти его позицию в вариационном ряду:

$$(n + 1) P / 100 = (26 + 1) 25 / 100 = (27) (0,25) = 6,75.$$

Просмотрим ранжированные варианты. Эта позиция находится между шестым и седьмым вариантами. Видим, что значение 6-го по порядку варианта равно 14. Значение 7-го по порядку варианта также равно 14. Отсюда 25-й перцентиль равен 14.

50-й перцентиль

1) Найти значение варианта, соответствующего позиции:

$$(n + 1) P / 100 = (26 + 1) 50 / 100 = (27) (0,5) = 13,5$$

Просмотрим ранжированные варианты. Видим, что значение 13-го по порядку варианта равно 15. Значение 14-го по порядку варианта также равно 15. Отсюда 50-й перцентиль равен 15.

90-й перцентиль

Определяем 90-й перцентиль как значение варианта, соответствующего позиции

$$(n + 1) P / 100 = (26 + 1) 90 / 100 = (27) (0,9) = 24,3.$$

Значение 24-го варианта равно 21, а 25-го равно 23, следовательно, расстояние от 21 до 90-го перцентиля составляет 0,3 от длины отрезка между 21 и 23 (длина отрезка равна 2). Поэтому 90-й перцентиль равен 21,6.

10. По данным таблицы 2 вычислить медиану (используйте формулу для нахождения медианы внутри медианного интервала).

Таблица 2	
Интервалы	Число регионов
До 60	10
60-70	29
70-80	2
80-90	13
90-100	-
Свыше 100	6

Медианному интервалу соответствует первая из накопленных частот или частостей, превышающая половину всего объема совокупности.

Внутри медианного интервала расчет значения медианы производится по формуле:

$$Me = x_{Me(min)} + k_i \frac{0,5 \cdot \sum m_i - v_{Me-1}}{m_{Me}} \quad (2),$$

где $x_{Me(min)}$ - нижняя граница медианного интервала;

k_i - величина медианного интервала (интервальная разность);

v_{Me-1} – накопленная частота или частость интервал, предшествующего медианному;

$0,5 \sum m_i$ – половина суммы всех частот (или частостей);

m_{Me} – частота медианного интервала.

x_i	50-60	60-70	70-80	80-90	90-100	100-110
m_i	10	29	2	13	0	6

x_i	50-60	60-70	70-80	80-90	90-100	100-110
m_{xi}	10	39	41	54	54	60

$$Me = 60 + 10 \cdot ((0,5 \cdot 60 - 10) / 29) = 66,9$$

№11

11. По данным таблицы 2 вычислить моду (используйте формулу для нахождения моды внутри модального интервала).

Таблица 2	
Интервалы	Число регионов
До 60	10
60-70	29
70-80	2
80-90	13
90-100	-
Свыше 100	6

В случае, если вариационный ряд имеет равные интервалы, то модальный (содержащий моду) интервал определяется по наибольшей частоте, при неравных интервалах – по наибольшей плотности. Мода внутри модального интервала определяется по следующей формуле:

$$Mo = x_{Mo(min)} + k_i \frac{m_{Mo} - m_{Mo-1}}{(m_{Mo} - m_{Mo-1}) + (m_{Mo} - m_{Mo+1})},$$

где $x_{Mo(min)}$ - нижняя граница модального интервала;

m_{Mo} - частота модального интервала;

m_{Mo-1} - частота интервала, предшествующего модальному;

m_{Mo+1} - частота интервала, последующего за модальным;

k_i - величина модального интервала.

$$Mo = 60 + 10 * ((29 - 10) / ((29 - 10) + (29 - 2))) = 64,13$$

№12

12. Вычислите среднюю арифметическую для данных Задания № 1 по формулам:

- Средней арифметической;
- Средней арифметической взвешанной.

Среднее арифметическое является приближённой оценкой

теоретического среднего (математического ожидания — M) генеральной

совокупности величин $x_1, x_2, \dots, x_n$ и определяется по формуле

$$\bar{x} = M = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$M = (9+12+12\dots+27)/26 = 15,615$$

Взвешенная средняя арифметическая — равна отношению (суммы произведений значения признака к частоте повторения данного признака) к (сумме частот всех признаков).

$$\bar{x}_{ap} = \frac{\sum x_i n_i}{n}$$

$$M = (9*1+12*2\dots+27*1)/26 = 15,615$$

№13

13. Проверить насколько медиана и средняя арифметическая чувствительна к положению крайних значений ряда значений (для данных Задания № 1).

Среднее значение признака M

Среднее арифметическое является приближённой оценкой

теоретического среднего (математического ожидания — M) генеральной

совокупности величин $x_1, x_2, \dots, x_n$ и определяется по формуле

$$\bar{x} = M = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$M = (9 \cdot 1 + 12 \cdot 2 + \dots + 27 \cdot 1) / 26 = 15,615$$

Медиана – это такое значение признака, которого делит упорядоченное (ранжированное) множество данных пополам так, что одна половина всех значений оказывается меньше медианы, а другая – больше. Первым шагом при определении медианы является упорядочивание (ранжирование) всех значений по возрастанию или убыванию.

Просмотрим ранжированные варианты. Видим, что значение 13-го по порядку варианта равно 15. Значение 14-го по порядку варианта также равно 15. Отсюда 50-й перцентиль равен 15.

$$Me = 15$$

Среднее арифметическое очень чувствительно к так называемым «выбросам» — отдельным значениям, которые значительно отличаются от других в этом датасете, в большую или меньшую сторону. Среднее арифметическое зависит от количества значений в ряду.

Медиана менее чувствительна к выбросам, чем среднее арифметическое, и более устойчива к влиянию нескольких экстремальных значений. Медиана не зависит от значений признака на краях ряда значений. Медиана зависит от количества значений, а не от того, что показывает значение. Поэтому медиана более надежный показатель типичного значения признака.

№14

14. Может ли быть в одном ряду несколько мод? Обоснуйте.

Распределение может иметь и не одну моду. Когда все значения встречаются одинаково часто, принято считать, что такое распределение не имеет моды.

Бимодальное распределение имеет на графике две вершины, даже если частоты для двух вершин не строго равны. В последнем случае выделяют большую и меньшую моду. Во всей группе может быть и несколько локальных вершин распределения частот. Тогда выделяют наибольшую моду и локальные моды.