

Лабораторная работа № 8

"Регрессионный анализ: модели и методы"

Задание №2

Имеются следующие выборочные данные о стоимости квартир и их общей площади в некотором городе.

y	13.8	13.8	14	22.5	24	28	32	20.9	22	21.5	32	35	24	37.9	27.5
x	33	40	36	60	55	80	95	70	48	53	95	75	63	112	70

x - общая площадь квартиры в кв. м;

y - рыночная стоимость квартиры в тыс. у.е.

Задание 2.1 Построить график зависимости между переменными, по которому необходимо подобрать модель регрессии.

Решение:

1. График зависимости переменных X и Y строится в прямоугольной системе координат. На оси абсцисс откладываются значения факторного признака X , а по оси ординат — результативного признака Y . Учитывая небольшое число пар значений переменных, по каждой из них выделим пять интервалов, используя формулу:

$$h = (x_{\max} - x_{\min}) / k.$$

Для переменной X :

$$h = (112 - 33) / 5 = 15,8 \approx 16$$

Границы интервалов: 33; 49; 65; 81; 97; 113.

Для переменной Y :


$$h = (37,9 - 13,8) / 5 = 4,82 \approx 5$$

Границы интервалов: 13; 18; 23; 28; 33; 38.

На график наносятся точки, координаты которых соответствуют значениям X и Y .

Характер расположения точек на графике показывает, что связь между переменными может выражаться линейным уравнением регрессии

$$y' = b_0 + b_1x \quad (2)$$



Задание 2.2 Рассчитать параметры уравнения регрессии методом наименьших квадратов.

Таким образом, уравнение регрессии имеет вид

$$b_1 = 0,301813$$

$$b_0 = 4,774304$$

$$y' = 4.7743 + 0.3018 \cdot x$$

Коэффициент регрессии показывает, что при увеличении общей площади квартиры на 1 м² стоимость квартиры в среднем увеличивается на 0,3018 тыс. у. е.

Задание 2.3 Оценить качество уравнения с помощью средней ошибки аппроксимации.

При помощи Анализа данных выводим окно:

ВЫВОД ОСТАТКА

Наблюдение	Предсказанное Y	Остатки	Стандартные остатки
1	14,7341206	-0,934120603	-0,320906857
2	16,84680905	-3,046809045	-1,046697729
3	15,63955851	-1,639558507	-0,563252288
4	22,88306174	-0,383061737	-0,131596646
5	21,37399856	2,626001436	0,902133904
6	28,91931443	-0,919314429	-0,315820359
7	33,44650395	-1,446503948	-0,496930518
8	25,90118808	-5,001188083	-1,718103147
9	19,26131012	2,738689878	0,940846779
10	20,7703733	0,729626705	0,250655228
11	33,44650395	-1,446503948	-0,496930518
12	27,41025126	7,589748744	2,607374685
13	23,78849964	0,211500359	0,072658622
14	38,57731874	-0,677318737	-0,232685401
15	25,90118808	1,598811917	0,549254245

При помощи остатков вычисляем качество уравнения регрессии по формуле:

$A = \frac{ y - y' }{y}$
6,76898988
22,0783264
11,7111322
1,70249661
10,9416726
3,28326582
4,52032484
23,9291296
12,4485904
3,39361258
4,52032484
21,6849964
0,8812515
1,78712068
5,81386152
Сумма 135,465096
Ср. знач. 9,03100639

$$\bar{A} = \frac{1}{n} \times \sum_{i=1}^n \left| \frac{y_i - y'_i}{y_i} \right| \times 100\%$$

$$\bar{A} = \frac{135,465}{15} = 9,031 \%$$

Задание 2.4 Найти коэффициент эластичности.

При линейной форме связи средний коэффициент эластичности находится по формуле

$$\varepsilon = b_1 \times \frac{x}{\bar{y}}, \text{ где}$$

$\varepsilon =$	0,80587
-----------------	---------

Коэффициента эластичности показывает, что при увеличении общей площади квартиры на 1 % ее стоимость в среднем возрастает на 0.806 %.

Задание 2.5 Оценить тесноту связи между переменными с помощью показателей корреляции и детерминации.

При линейной зависимости, степень тесноты связи между переменными X и Y определяется с помощью коэффициента корреляции:

$$r = \frac{\overline{XY} - \bar{X}\bar{Y}}{\sigma_x \sigma_y}$$

где σ_x и σ_y - средние квадратические отклонения по X и Y .

$$\sigma_x = \sqrt{\overline{X^2} - \bar{X}^2} = \sqrt{4807.4 - 65.667^2} = 22.254;$$

$$\sigma_y = \sqrt{\overline{Y^2} - \bar{Y}^2} = \sqrt{657.857 - 24.593^2} = 7.283;$$

r	0,92241832
-----	------------

Так как значение коэффициента корреляции близко к единице, то между признаками связь очень тесная, прямая, близкая к линейной функциональной.

Коэффициент детерминации $r^2 = 0.922^2 = 0.850$ показывает, что 85 % различий в стоимости квартир объясняется вариацией их общей площади, а 15 % - другими, неучтенными факторами (местоположение квартир, благоустроенность территории и другими).

Задание 2.6 Оценить значимость коэффициентов корреляции и регрессии по критерию t-Стьюдента при уровне значимости $\alpha = 0.05$

Так как исходные данные являются выборочными, то необходимо оценить существенность или значимость величины коэффициента корреляции.

Выдвигаем нулевую гипотезу H_0 : коэффициента корреляции в генеральной совокупности равен нулю, и изучаемый фактор не оказывает существенного влияния на результативный признак.

$H_0: r_{xy} = 0$, при $H_1: r_{xy} \neq 0$.

Для проверки нулевой гипотезы применим t-критерий Стьюдента. Найдем расчетное значение t-критерий:

$$t_{\text{расч}} = \frac{|r|}{\sqrt{\frac{1-r^2}{n-2}}} = \frac{0.922}{\sqrt{\frac{1-0.922^2}{15-2}}} = 8.58.$$

t расч	8,61184179
--------	------------

Критическое значение t находится по таблицам t-распределения Стьюдента при уровне значимости $\alpha = 0.05$ и числе степеней свободы $k = n - 2 = 15 - 2 = 13$.

Для двусторонней критической области $t_{\text{кр}} = 2.16$.

11	0,13	0,26	0,40	0,54	0,70	0,86	1,09	1,36	1,80	2,20
Продолжение прил.										
Число степеней свободы k	Вероятность γ									
	0,1	0,2	0,3	0,4	0,5	0,6	0,7	0,8	0,9	0,95
12	13	26	39	54	69	87	98	36	78	15
13	13	26	39	54	69	87	98	35	77	14

Сравним $t_{\text{расч}}$ с $t_{\text{кр}}$. Так как $t_{\text{расч}} > t_{\text{кр}}$, то нулевая гипотеза отвергается, коэффициент корреляции существенно отличен от нуля в генеральной совокупности. Значит, общая площадь квартир оказывает статистически существенное влияние на стоимость.

Статистическая значимость коэффициента регрессии также проводится с использованием t-критерия Стьюдента.

Находится расчетное значение критерия:

$$t_{\text{расч}} = \frac{b_1}{m_{b_1}};$$

$$m_{b_1} = \sqrt{\frac{\sum(y - \bar{y})^2}{(n - 2) * \sum(x - \bar{x})^2}} = \sqrt{\frac{\sum(y - \bar{y})^2}{(n - 2) * \sigma_x^2 * n}}$$

$$= \sqrt{\frac{118.625}{(15 - 2) * 22.254^2 * 15}};$$

$$t_{\text{расч}} = \frac{0.3018}{0.035} = 8.62.$$

Критическое значение t также равно 2.16. Так как $t_{\text{расч}} > t_{\text{кр}}$, то коэффициент регрессии статистически значим. Подтверждается вывод о значимости влияния общей площади на стоимость квартир.

Задание 2.7 Охарактеризовать статистическую надежность результатов регрессионного анализа с использованием критерия F-Фишера при уровне значимости $\alpha = 0.05$.

Статистическая надежность уравнения регрессии проверяется с использованием критерия F-Фишера

Расчетное (фактическое) значение F-критерия находится по формуле:

$$F_{\text{расч}} = \frac{\sum(y - \bar{y})^2 / k}{\sum(y - \bar{y})^2 / (n - k - 1)};$$

где k – число параметров при переменных X .

Если применяется линейное уравнение регрессии, то расчетное $F_{\text{расч}}$ упрощается.

$$F_{\text{расч}} = \frac{r^2}{1 - r^2} (n - 2) = \frac{0.85}{1 - 0.85} * 13 = 73.67.$$

Ак

F расч	74,163819
--------	-----------

При уровне значимости $\alpha = 0.05$ и числе степеней свободы $k_1 = k = 1$, $k_2 = n - k - 1 = 15 - 1 - 1 = 15 - 2 = 13$ по таблице находится критическое значение F –критерия. $F_{\text{кр}} = F_{0.05;1,13} = 4.67$.

$k_2 \backslash k_1$	1
1	161
2	18,5
3	10,1
4	7,71
5	6,61
6	5,99
7	5,59
8	5,32
9	5,12
10	4,96
11	4,84
12	4,75
13	4,67

Так как $F_{\text{расч}} > F_{\text{кр}}$, то уравнение регрессии статистически значимое или надежное.

При парной линейной зависимости оценка значимости всего уравнения, коэффициентов корреляции и регрессии дает одинаковые результаты, так как

$$t_{b_1}^2 = t_r^2 = F_{\alpha, k_1, k_2}.$$

Задание 2.8 Определить прогнозное значение результативного признака, если возможное значение факторного признака составит 1.2 от его среднего уровня по совокупности.

Прогнозное значение результативного признака определяется путем подстановки в уравнение регрессии прогнозного или возможного значения факторного признака (x_p).

По условию $x_p = \bar{x} * 1.2 = 65.667 = 78.8$.

x_p	78,8
-------	------

Тогда прогнозное значение стоимости квартиры составит

$$y'_p = b_0 + b_1 * x_p = 4.7743 + 0.3018 * 78.8 = 28.56.$$

y'_p	28,5571393
--------	------------

Значит при общей площади квартиры в 78.8 м² возможная стоимость квартиры составляет 25.56 тыс. у.е.

Лекционная задача

Задача. В таблице 1. содержатся данные о распаде 10г радиоактивного вью-ва, где t - время (в минутах), X - кол-во (г) оставшегося вью-ва в момент времени t. Показать, что процесс распада подчиняется экспоненциальному закону, найти его параметры, составленную дисперсию и доверительный интервал для X_0 при $\alpha = 5$.

Таблица

t	1	2	3	4	5	6	7	8	9	10	11	12
X	8.453	7.666	6.947	6.288	5.684	5.134	4.635	4.187	3.792	3.458	3.182	2.961

Решение

- Предположим, что ф-ия регрессии имеет вид $x = a e^{bt}$ (1)
- Логарифмируем (1): $\ln x = \ln a + bt$. (2)
- Возьмем $y = \ln x$, $a' = \ln a$. (3)
- Тогда ур-ие (2) примет вид $y = a' + bt$. (4)

Это линейное ур-ие регрессии.
Для нахождения его параметров исп-ем уже рассмотренный алгоритм.

6. По формулам

$$a = \frac{\sum_{i=1}^n y_i \cdot \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i \cdot \sum_{i=1}^n x_i \cdot y_i}{n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i \right)^2} \quad (x)$$

$$b = \frac{n \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \cdot \sum_{i=1}^n y_i}{n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i \right)^2} \quad (y)$$

Можно обозначить

$$\sum_{i=1}^n x_i = n\bar{x}, \quad \sum_{i=1}^n y_i = n\bar{y}, \quad \sum_{i=1}^n x_i^2 = n\overline{x^2}$$

$$\sum_{i=1}^n x_i y_i = n\overline{xy}$$

Тогда

$$a = \frac{\overline{y} \cdot \overline{x^2} - \bar{x} \cdot \overline{xy}}{\overline{x^2} - (\bar{x})^2}, \quad b = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\overline{x^2} - (\bar{x})^2}.$$

a'	2,155236103
----	-------------

b	-0,156456459
---	--------------

$$y = 2,155 - 0,156t$$

Найдём

$$a = \exp(a')$$

a	8,629927494
---	-------------

Тогда ур-ие регрессии (1) имеет вид

$$x = 8,63e^{-0,156t}$$