

Крупнейшие базы данных мира

Практическое задание № 4

2024–2025 учебный год

Содержание

Содержание	2
1. Что такое база данных?	3
2. Что такое банк данных?	3
3. В чём отличие базы данных от банка данных?	3
4. Что такое Big Data?	5
5. Что такое СУБД?	5
6. Что такое аналитика больших данных?	6
7. Поставщики Big Data в России	6
8. Поставщики Big Data в мире	7
8.1. Облачные платформы и инфраструктура	7
8.2. Технологические платформы (Open Source)	7
8.3. Аналитика и бизнес-интеллект	7
8.4. Специализированные компании	7
9. Технические характеристики баз данных	8
9.1. Модель данных	8
9.2. Масштабируемость	8
9.3. Производительность	8
9.4. Надёжность и доступность	8
9.5. Безопасность	8
10. Используемые ресурсы	9

1. Что такое база данных?

База данных (БД) — это организованная совокупность структурированной информации или данных, хранящихся в электронном виде в компьютерной системе. Как правило, база данных управляется системой управления базами данных (СУБД).

Данные и СУБД вместе с приложениями, которые с ними работают, называются системой базы данных, или просто базой данных.

Основные характеристики баз данных:

- Структурированность — данные организованы по определённым правилам и схемам
- Совместный доступ — несколько пользователей могут работать с данными одновременно
- Независимость данных — изменение структуры хранения не влияет на прикладные программы
- Целостность — данные защищены от некорректных изменений и ошибок
- Безопасность — разграничение прав доступа к данным

2. Что такое банк данных?

Банк данных — это система специальным образом организованных данных (баз данных), программных, технических, языковых и организационно-методических средств, предназначенных для обеспечения централизованного накопления и многоцелевого использования информации.

Банк данных является более широким понятием, чем база данных, и включает:

- Одну или несколько баз данных
- СУБД (систему управления базами данных)
- Прикладные программы для работы с данными
- Технические средства (серверы, хранилища)
- Административный персонал и документацию

3. В чём отличие базы данных от банка данных?

База данных и банк данных — понятия взаимосвязанные, но не тождественные. Их ключевые отличия:

База данных	Банк данных
Совокупность данных на определённую тему	Комплекс данных + средств управления ими
Является частью банка данных	Включает одну или несколько БД
Только хранилище данных	Полноценная информационная система
Не включает программное обеспечение	Содержит СУБД и прикладные программы

4. Что такое Big Data?

Big Data (большие данные) — это наборы данных, которые являются настолько большими или сложными, что традиционные методы обработки данных не позволяют с ними работать эффективно. Термин охватывает как сами данные, так и технологии и методы их обработки.

Концепцию Big Data принято описывать через «5 V»:

- Volume (Объём) — огромные объёмы данных (от терабайт до зеттабайт)
- Velocity (Скорость) — высокая скорость генерации и обработки данных в реальном времени
- Variety (Разнообразие) — структурированные, полуструктурированные и неструктурированные данные
- Veracity (Достоверность) — неоднородность и ненадёжность части данных, необходимость их верификации
- Value (Ценность) — извлечение полезной информации из массивов данных для принятия решений

Примеры источников Big Data: социальные сети, интернет вещей (IoT), транзакционные системы, медицинские записи, геолокационные данные, видеонаблюдение.

5. Что такое СУБД?

СУБД (Система управления базами данных) — это программный комплекс, предназначенный для создания, ведения и использования баз данных. СУБД обеспечивает интерфейс между пользователями или прикладными программами и базой данных.

Основные функции СУБД:

- Определение данных — задание структуры и типов хранимых данных
- Манипуляция данными — добавление, изменение, удаление и выборка данных
- Защита и безопасность — управление правами доступа и шифрование
- Обеспечение целостности — поддержание согласованности данных
- Управление транзакциями — атомарность операций (принцип ACID)
- Резервное копирование и восстановление данных

Примеры популярных СУБД: Oracle Database, Microsoft SQL Server, MySQL, PostgreSQL (реляционные); MongoDB, Cassandra, Redis (NoSQL); ClickHouse, Apache Hive (для Big Data).

6. Что такое аналитика больших данных?

Аналитика больших данных — это комплекс технологий, методов и инструментов для исследования больших массивов данных с целью выявления скрытых закономерностей, неизвестных корреляций, тенденций рынка и потребительских предпочтений.

Выделяют несколько уровней аналитики:

- Дескриптивная аналитика — описание того, что произошло (отчёты, дашборды)
- Диагностическая аналитика — выяснение причин произошедшего
- Предиктивная аналитика — прогнозирование будущих событий на основе исторических данных и моделей машинного обучения
- Прескриптивная аналитика — выработка рекомендаций для принятия оптимальных решений

Инструменты аналитики больших данных: Apache Hadoop, Apache Spark, Hive, Kafka, ClickHouse, Tableau, Power BI, Python (pandas, scikit-learn), R.

7. Поставщики Big Data в России

Ниже представлены ведущие российские компании — поставщики технологий и решений в области больших данных:

№	Компания	Направление / продукты
1	Сбер (Сбербанк)	Платформа ML Space, SberCloud, анализ транзакций и клиентских данных
2	Яндекс	Яндекс.Облако, обработка поисковых запросов, картографические и рекламные данные
3	МТС (МТС AI)	Телеком-данные, предиктивная аналитика, платформа МТС Линк
4	VK (ВКонтакте)	Социальные данные, рекламная аналитика, рекомендательные системы
5	Ростелеком	Инфраструктурные данные, платформа CORM, BI-аналитика для государства
6	Mail.ru Group / VK Tech	Облачные платформы, почта, мессенджеры — большие объёмы пользовательских данных
7	Газпром нефть (GPN DS)	Аналитика нефтедобычи, промышленный IoT, геологические данные

8. Поставщики Big Data в мире

Мировой рынок больших данных формируют несколько категорий игроков:

8.1. Облачные платформы и инфраструктура

- Amazon Web Services (AWS) — Amazon Redshift, S3, Kinesis, EMR
- Microsoft Azure — Azure Synapse Analytics, HDInsight, Data Lake
- Google Cloud Platform — BigQuery, Dataflow, Pub/Sub, Vertex AI
- Snowflake — облачное хранилище данных с поддержкой мультиоблака

8.2. Технологические платформы (Open Source)

- Apache Software Foundation — Hadoop, Spark, Kafka, Flink, HBase
- Databricks — коммерческая платформа на базе Apache Spark
- Cloudera — корпоративный дистрибутив Hadoop

8.3. Аналитика и бизнес-интеллект

- Tableau (Salesforce) — визуализация и анализ данных
- Palantir Technologies — аналитика данных для государственного и корпоративного сектора
- SAS Institute — статистический анализ и машинное обучение
- IBM (Watson, Db2) — корпоративная аналитика и AI

8.4. Специализированные компании

- Nielsen — исследования потребительского рынка и медиааудитории
 - Dun & Bradstreet — бизнес-данные и кредитная аналитика
 - LexisNexis — правовые и новостные базы данных
-

9. Технические характеристики баз данных

Технические характеристики описывают возможности и параметры конкретной базы данных или СУБД:

9.1. Модель данных

- Реляционная (табличная) — Oracle, PostgreSQL, MySQL, MS SQL Server
- Документоориентированная — MongoDB, CouchDB
- Ключ-значение — Redis, DynamoDB
- Графовая — Neo4j, Amazon Neptune
- Колончатая — Apache Cassandra, ClickHouse, HBase
- Временные ряды — InfluxDB, TimescaleDB

9.2. Масштабируемость

- Вертикальное масштабирование (scale-up) — увеличение мощности одного сервера
- Горизонтальное масштабирование (scale-out) — добавление новых узлов кластера
- Шардирование — горизонтальное разбиение данных по нескольким серверам

9.3. Производительность

- Пропускная способность — число операций в секунду (TPS / QPS)
- Задержка (latency) — время отклика при выполнении запроса
- Индексирование — B-Tree, Hash, GIN, GiST, Full-Text и другие типы индексов

9.4. Надёжность и доступность

- Репликация — синхронная и асинхронная
- Резервное копирование и точка восстановления (RPO/RTO)
- Поддержка ACID-транзакций или BASE-консистентности (для NoSQL)

9.5. Безопасность

- Аутентификация и авторизация пользователей
 - Шифрование данных в покое (at rest) и в транзите (in transit)
 - Аудит операций и журналирование
-

10. Используемые ресурсы

Список использованных источников оформлен в соответствии с ГОСТ Р 7.0.100–2018:

- Дейт К. Дж. Введение в системы баз данных. — 8-е изд. — М.: Вильямс, 2006. — 1328 с.
 - Кузнецов С. Д. Основы баз данных. — 3-е изд. — М.: Интернет-университет информационных технологий, 2019. — 488 с.
 - Big Data: крупнейшие базы данных мира [Электронный ресурс] // vc.ru. — URL: <https://vc.ru/u/549605-octoparse/140322> (дата обращения: 14.04.2025)
 - Amazon Web Services [Электронный ресурс]. — URL: <https://www.amazon.com> (дата обращения: 14.04.2025)
 - Google Cloud Big Data [Электронный ресурс]. — URL: <https://www.google.com> (дата обращения: 14.04.2025)
 - World Data Center for Climate [Электронный ресурс]. — URL: <https://www.ncdc.noaa.gov> (дата обращения: 14.04.2025)
 - Nielsen. Медиааналитика и исследование рынков [Электронный ресурс]. — URL: <https://www.nielsen.com/ru/ru> (дата обращения: 14.04.2025)
 - Apache Hadoop [Электронный ресурс] // hadoop.apache.org. — URL: <https://hadoop.apache.org> (дата обращения: 14.04.2025)
-